



第五章 语音识别 复习

目录

- 语音识别概念
(音节、音素、音位)
- ◆ 特征提取
流程
MFCC
- ◆ 孤立词识别技术
DTW
GMM
- ◆ 语音识别技术
HMM
大词汇量的情况
- ◆ 语音识别系统
基于 GMM-HMM的语音识别系统
基于神经网络的语音识别系统

语音基本概念

- 音节

听觉能够自然察觉到的最小语音单位，音节有声母、韵母、声调三部分组成。一个汉字的读音就是一个音节，一个英文单词可能有一个或多个音节构成。

- 音素

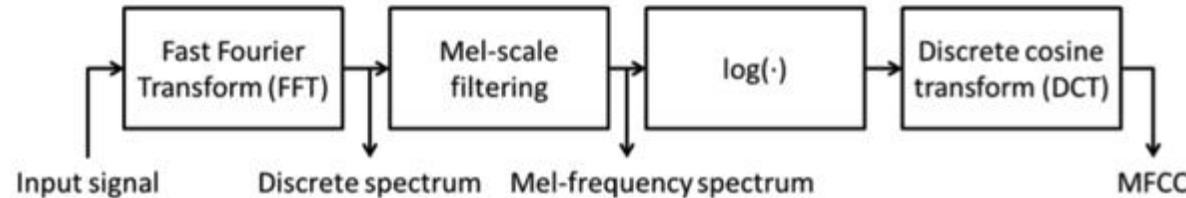
从音节中分析出来的最小语音单位，语音分析到音素就不能再分了。比如，“她穿红衣服”是5个音节，而“红”又可进一步分为3个音素--h,o,ng。

- 音位：

能够区分意义的音素，比如bian,pian,bu,pu就是靠b, p两个音素来区分的，所以b, p就是两个音位。

特征提取

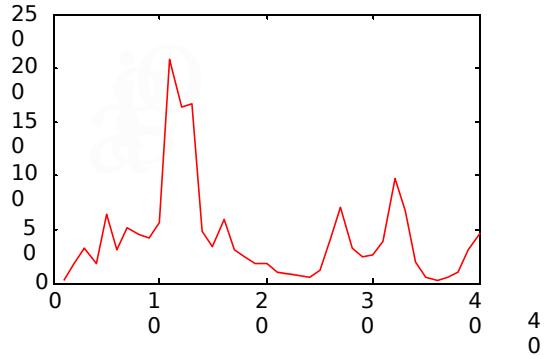
- 流程



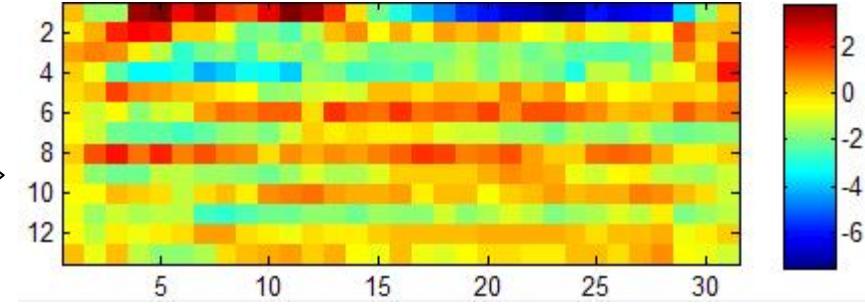
- 截取出信号帧，通常 $20 \sim 50$ ms
- 傅里叶变换计算频谱
 - 精细结构反映音高，用处较小
 - 包络反映音色，是主要信息
- 三角滤波得到近似频谱包络（Mel spectrum）
 - 目的：模拟人耳响应随频率的特性
- 近似频谱包络得到MFCC

特征提取

- MFCC



log,
DCT



- Cepstrum: $\bar{X}(q) = \text{IFFT}(\log|X(f)|)$

- Log
- DCT, 信号回到cepstral (正比于频率倒数) 而非时域

-优点：排除基频，符合听觉，维度低
-缺点：视野小，受噪声、回声、滤波影响严重

孤立词识别技术

- 模板比较法
 - 1个模板：动态时间调整算法（DTW）
 - 多个模板：高斯混合模型（GMM）

孤立词识别技术

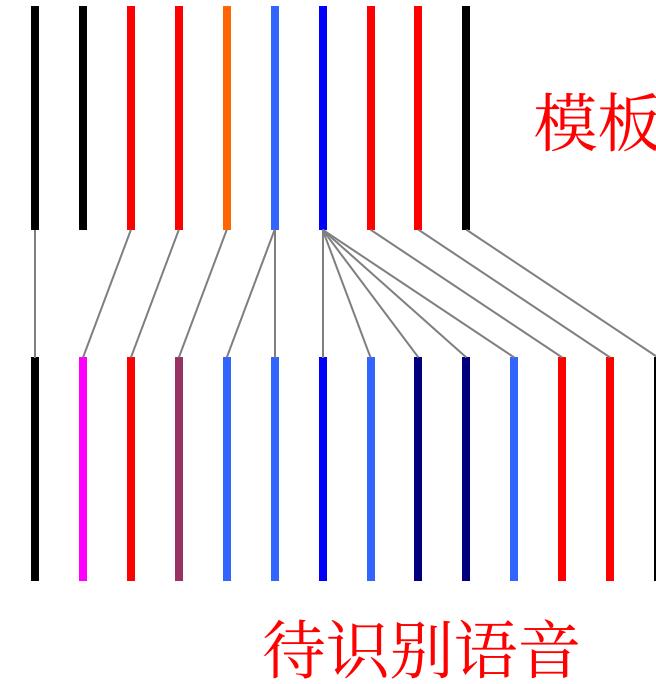
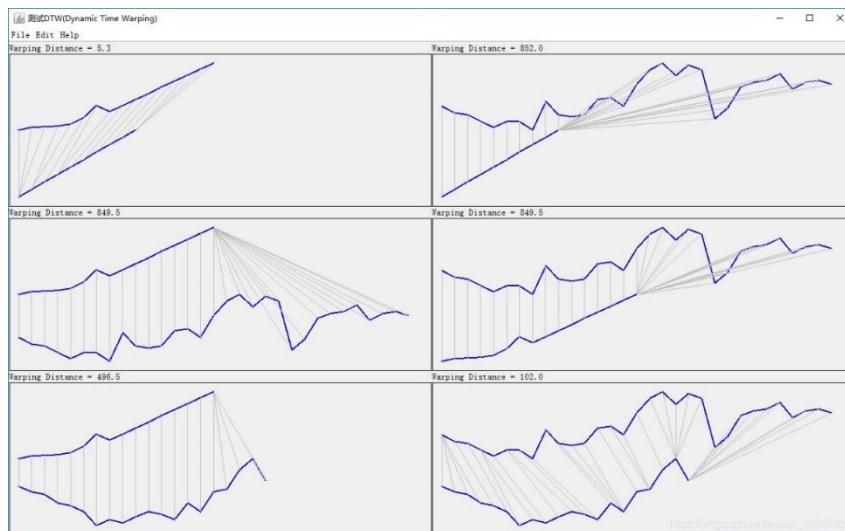
- DTW

计算两个不同长度、不同节奏的时间序列的相似度

采用动态规划DP方法，扭曲时间序列的形态

按照顺序，让每一帧与模板中最相似的一帧匹配

总距离为各帧的 欧氏距离之和



孤立词识别技术

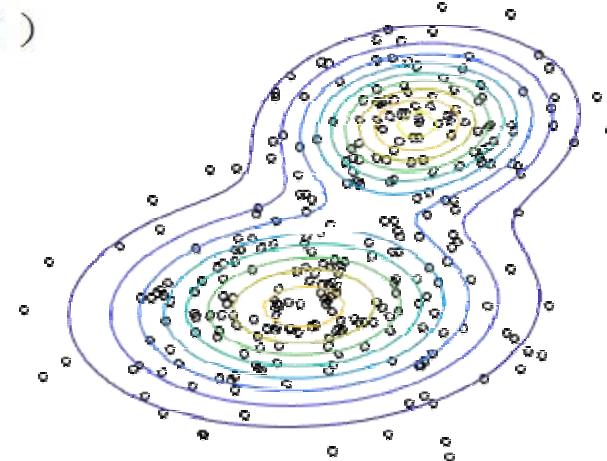
- GMM

多个高斯分布函数的叠加，理论上能够拟合任意分布

用GMM概率密度代替特征向量间的欧氏距离

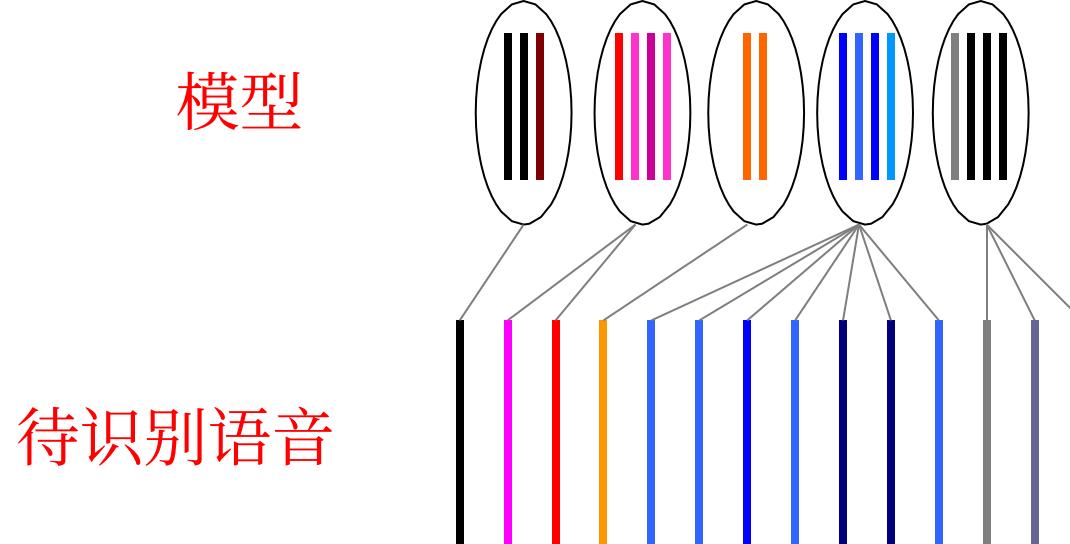
高斯分布: $f(x) = \frac{1}{\sqrt{2\sigma^2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$

GMM: $f(x) = \sum_i^k \phi_i \frac{1}{\sqrt{2\sigma_i^2\pi}}e^{-\frac{(x-\mu_i)^2}{2\sigma_i^2}}$ ($\sum_i^k \phi_i = 1$)



孤立词识别技术

- GMM
 - DTW对齐待识别语音与模型
 - 计算模型每个状态的GMM
 - 对于一帧的MFCC，计算每个状态的GMM模型的概率 $P(\text{待识别语音} | \text{模型})$
 - 取概率最大的模型为识别结果



语音识别技术

◆ 隐马尔可夫模型 (HMM)

包含:

$$\Pi = (\pi_i) \quad : \text{初始化概率向量;}$$

$$A = (a_{ij}) \quad : \text{状态转移矩阵; } Pr(x_{i_t} | x_{j_{t-1}})$$

$$B = (b_{ij}) \quad : \text{混淆矩阵; } Pr(y_i | x_j)$$

状态转移矩阵:

π 向量: 定义系统初始化时每一个状态的概率

$$Yester day \quad \begin{matrix} & & & Today \\ & sun & \left[\begin{array}{ccc} sun & cloud & rain \\ 0.50 & 0.375 & 0.125 \\ 0.25 & 0.125 & 0.625 \\ 0.25 & 0.375 & 0.375 \end{array} \right] \\ & cloud & \\ & rain & \end{matrix}$$



语音识别技术

◆ 隐马尔可夫模型 (HMM)

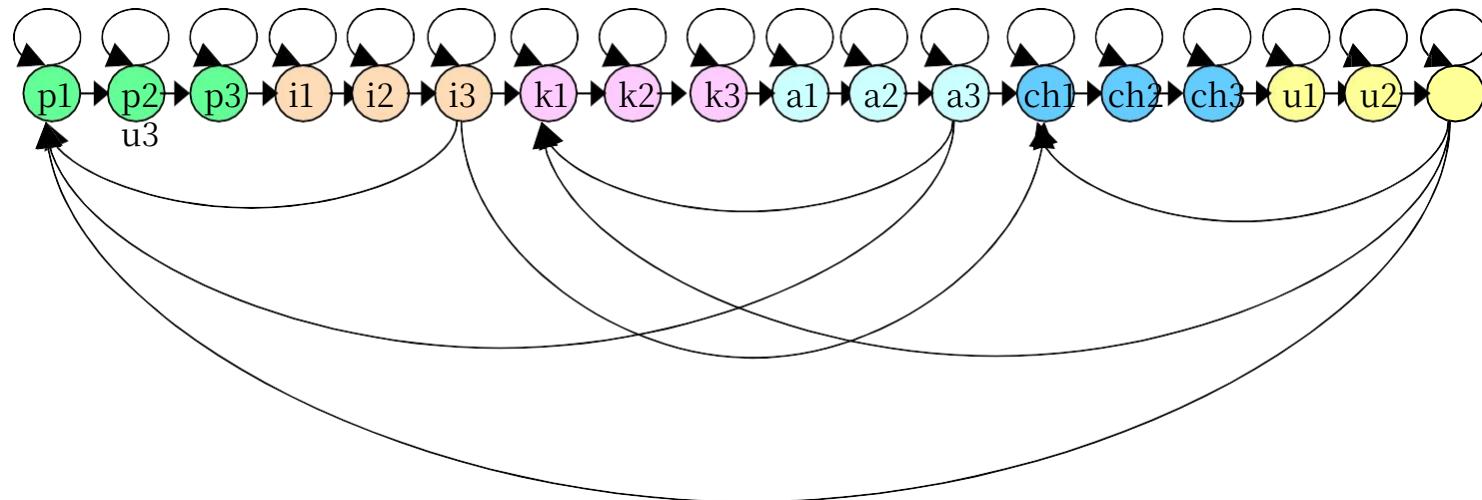
- 1.DTW对齐待识别语音与模型
- 2.计算每个音素的HMM
- 3.对于一帧的MFCC，计算每个音素的HMM模型的概率 $P(\text{待识别语音} | \text{模型})$
- 4.取概率最大的模型为识别结果



$$W^* = \arg \max_{W} P(W | X) = \frac{\arg \max_{W} P(X | W)}{\arg \max_{W} P(W)}$$

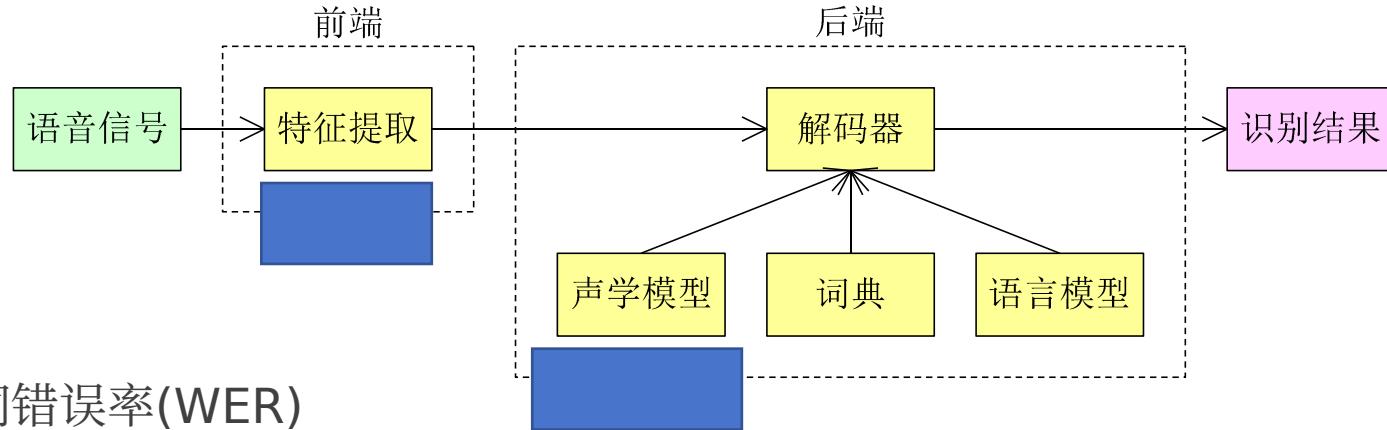
语音识别技术

- 大词汇量语音识别
 - 不能为每个单词训练单独的HMM
 - 改为每个音素训练一个HMM
 - HMM的复合:
 - 音素HMM按词典拼接成单词HMM
 - 单词HMM与语言模型复合成语言HMM



语音识别系统

- 基于 GMM-HMM的语音识别系统
 - 结构



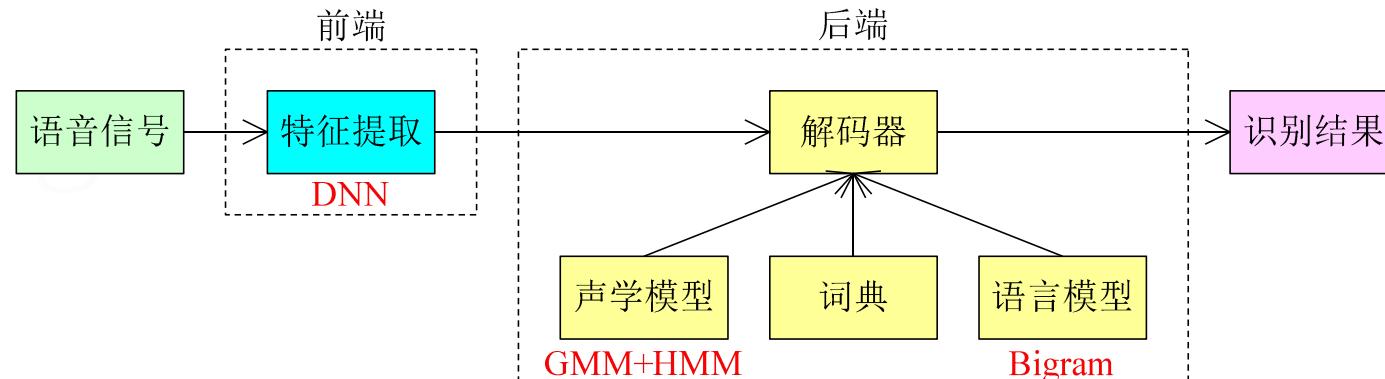
- 评价指标：词错误率(WER)
 - 用插入、删除、替换错误的总数除以标准 答案的长度



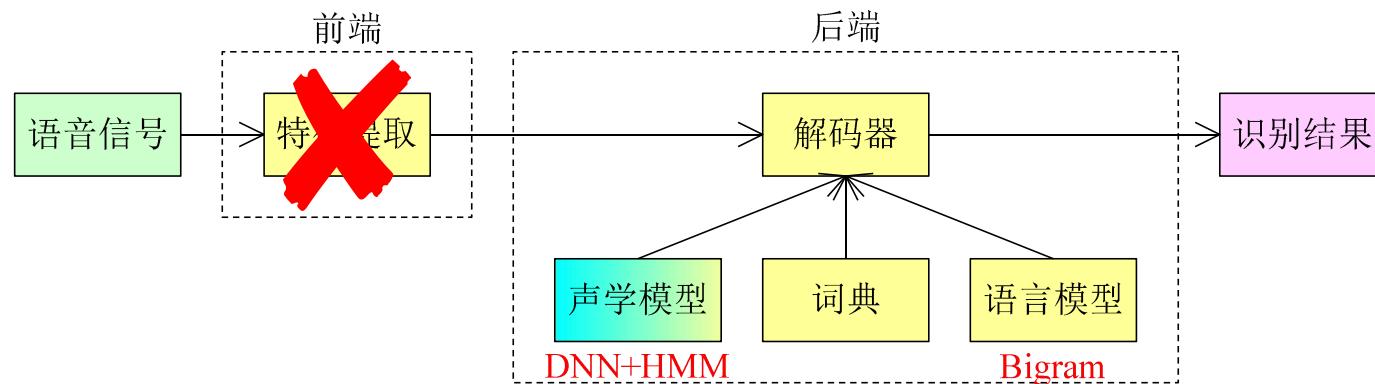
语音识别

- 基于神经网络的语音识别系统

- Tandem结构



- Hybrid结构



语音识别

- 基于神经网络的语音识别系统
 - 3. 直接使用
循环神经网络 (recurrent neural network, RNN)

理想：直接替代

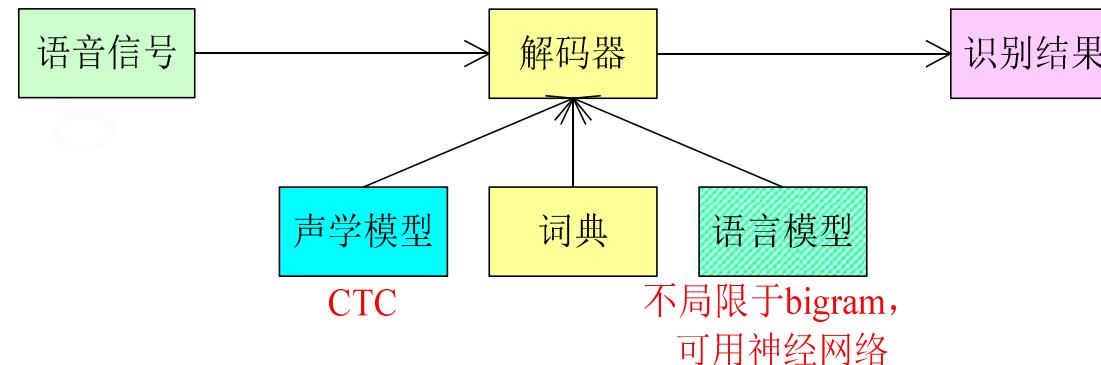
实际：代替DNN用于特征提取或声学模型，
HMM保留

- 训练时提供各音素起止时间
- 解码时提供状态转移概率

语音识别

- 基于神经网络的语音识别系统

4. Grapheme系统



CTC

端到端，只关心预测输出的序列是否和真实的序列接近
不需要预先做对齐或转移概率