

语音识别基础复习提纲（入门友好版）

一、语音基本概念

1. 音节 (syllable)

- **定义**：听起来像“一个拍子”的语音单位。
- **汉语**：一般 **一个字 = 一个音节**
 - 例：“**红**” = 一个音节
- **英语**：一个单词可以有多个音节
 - 例：“**computer**” 有 3 个音节：com / pu / ter

2. 音素 (phone)

- **定义**：从音节中拆出的最小语音单位，不能再分。
- 例：“**红**” 的读音 /hong/ 可以拆成 3 个音素：
 - h、o、ng
- 你可以把 **音素** 理解成“发音的小块积木”。

3. 音位 (phoneme)

- **定义**：能区分词义 的音素类别。
- 例：
 - **b** 和 **p**：
 - “bian” vs “pian”
 - “bu” vs “pu”
 - 因为 b 和 p 会让词的意思变了 → 所以它们是不同的 **音位**。

二、特征提取（MFCC 是核心）

机器不能直接理解“生的波形”，
所以先要把一段语音 → 变成一串数字特征。

（一）基本流程（非常重要）

1. 分帧（frame）

- 把连续的语音信号按时间切成一段一段
- 每帧长度：一般 **20–50 ms**
- 理由：这么短的时间内，声音可以近似看作“稳定”的

2. 做傅里叶变换 → 得到频谱

- 把“时间信号” → 变成“频率信号”
- 频谱可以理解为：
每个频率上有多大能量
- 频谱里：
 - **包络（envelope）**：整体形状 → 和音色、语音内容更相关
 - **精细结构**：细细的波动 → 和音高（pitch）更相关

3. 用三角滤波器 → 得到 Mel 频谱

- 用很多个重叠的“**三角形滤波器**”在频率轴上做加权。
- 这些滤波器的中心频率不是均匀的，而是按 **Mel 频率尺度** 分布
- 目的：**模拟人耳对频率的感知**：
 - 低频：人耳更敏感
 - 高频：分辨能力差一些 → 用更稀疏的滤波器

4. 从 Mel 频谱 → 提取 MFCC 特征

- 对 Mel 频谱做一系列数学处理（log + DCT 等）
- 得到一串系数：**MFCC（Mel 频率倒谱系数）**

（二）MFCC（Mel-Frequency Cepstral Coefficients）

可以简单记：
“描述语音音色的低维特征”。

1. 公式大意

你不需要死记公式，只要知道大致过程：

1. 对每一帧语音做 FFT → 得到频谱 $|X(f)|$

2. 取对数： $\log |X(f)|$
3. 做 DCT（离散余弦变换），把频域信息变到“倒谱域”

可以简写成（概念上）：

倒谱 = IFFT($\log$ |频谱|)

得到的系数就是 **倒谱系数**，选前面几维就是 **MFCC**。

2. MFCC 的优点

- **去掉基频信息**，更关注“音色”，对说话内容更有用
- 符合人耳对声音的感知习惯（Mel 频率尺度）
- **维度低**（通常十几维），便于后续建模

3. MFCC 的缺点

- 每次只看一个短帧 → “**视野**”比较小
- 容易受到：
 - 噪声
 - 回声
 - 录音设备滤波 的影响

三、孤立词识别（只识别单个词）

“**孤立词**”：一次只说一个词，中间有明显停顿。

例如：说一声“开启”，系统只需要识别这一个词。

（一）模板比较法

两种常见方式：

1. **单模板：DTW（动态时间规整 / 扭曲）**
 - 每个词只有一个模板
 - 用 DTW 对齐待识别语音和模板，算相似度
2. **多模板：GMM（高斯混合模型）**
 - 每个词用一个 GMM（或者多个状态，每个状态一个 GMM）
 - 用**概率密度**来衡量相似度，而不是简单的欧氏距离

(二) DTW (Dynamic Time Warping)

解决的问题：

- 两段语音：
 - 内容相同
 - 但说话速度不同、长短不同
- 普通按时间对齐会对不上 → 需要“时间扭曲”

核心思想：

- 把两条时间序列（特征向量序列）按顺序对齐
- 允许“拉伸”或“压缩”时间轴
- 使用动态规划算法，找到总距离（一般是欧氏距离之和）最小的对齐路径
- 最小总距离 = 两段语音的“不相似程度”

(三) GMM (Gaussian Mixture Model)

1. 是什么？

- 多个高斯分布的加权和：
 - 一个高斯拟合不了复杂数据
 - 很多高斯叠加起来，就可以拟合非常复杂的分布

2. 单个高斯分布公式（记个形状就好）：

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- μ ：均值
- σ^2 ：方差

GMM 就是很多这样的高斯分布相加。

3. 训练方法：EM（期望最大化）算法

- 交替两步：
 - E 步：根据当前参数，估计每个样本属于哪个高斯的概率
 - M 步：根据这些概率，重新更新每个高斯的参数（均值、方差、权重）

4. 用在孤立词识别的流程（简化版）：

1. 对语音做 **DTW**（必要时）对齐到统一时间尺度
2. 把每个词建模成若干状态，每个状态用一个 GMM
3. 输入一段新语音 → 提取 MFCC
4. 计算这段 MFCC 在每个词模型上的概率
5. 哪个词模型概率最高 → 识别为哪个词

四、连续语音识别：HMM 与大词汇量识别

（一）HMM（隐马尔可夫模型）

用来描述：“隐藏的状态序列”产生“可观察到的特征序列”。

在语音识别里：

- **隐藏状态**：音素的状态（如某个音素的开始 / 中间 / 结束状态）
- **观测值**：每一帧的特征（MFCC）

1. HMM 的三个核心部分：

1. 状态转移矩阵 $\mathbf{A} = (a_{ij})$

- 表示从状态 j 跳到状态 i 的概率：
- $a_{ij} = P(x_t = i \mid x_{t-1} = j)$

2. 观测概率矩阵 $\mathbf{B} = (b_j(k))$

- 表示在状态 j 下，产生观测值 y_k 的概率：
- $b_j(k) = P(y_k \mid x_j)$
- 在语音里，常用 GMM 或神经网络来表示这个概率

3. 初始状态分布 π

- 一开始在各个状态的概率 $\pi_i = P(x_1 = i)$

2. 用 HMM 做识别（简化理解）：

目标：给定特征序列 X ，找到最可能的词序列 W 。

$$W^* = \arg \max_W P(W \mid X) = \arg \max_W \frac{P(X \mid W)P(W)}{P(X)}$$

- $P(X \mid W)$ ：声学模型（HMM）给出的“发出这些特征的概率”
- $P(W)$ ：语言模型给出的“这句话在语言上是否合理的概率”
- $P(X)$ ：对所有 W 都一样，可忽略

(二) 大词汇量语音识别 (LVCSR)

当词汇量**非常大**（几千、几万词）时：

- 如果给 **每个词单独建一个 HMM**，会非常麻烦
- 解决方法：**按“音素”建模，而不是按“词”**

1. 核心策略

- 不为单个单词训练 HMM
- 改为：**为每个音素训练一个 HMM**

2. 组合方式

1. 音素 HMM → 单词 HMM

- 用词典告诉你：
 - 这个词由哪些音素构成
- 把对应音素的 HMM 串联起来，就得到这个词的 HMM

2. 单词 HMM + 语言模型 → 句子 HMM（或更大的网络）

- 语言模型告诉你：
 - 某个词后面接另一个词的概率有多大
- 和 HMM 结合后，就可以在**词序列**上做解码

五、语音识别系统评价与深度学习方法

(一) 基于 GMM-HMM 的传统系统

1. 结构：

- 前端特征：MFCC
- 声学模型：GMM-HMM
- 语言模型：n-gram 等

2. 核心评价指标：WER（词错误率）

$$\text{WER} = \frac{\text{插入错误数} + \text{删除错误数} + \text{替换错误数}}{\text{参考答案（标准文本）的词数}}$$

- 插入：系统多识别了一个本来没有的词
- 删除：系统漏掉了一个应该识别出的词

- 替换：把一个词认错成了另一个词

(二) 基于神经网络的语音识别

1. 常见结构

- **Tandem 结构**
 - 神经网络先做特征提取
 - 提取出的“高级特征”再送进 GMM-HMM
- **Hybrid 结构**
 - 神经网络直接代替 GMM，给出 HMM 每个状态的发射概率